

Análisis Integral y Estado del Arte para el Diseño de un Sistema de Visión y Control Co-simulado en la Pulverización Selectiva de Oídio en Vid

Introducción al Paradigma de la Viticultura de Precisión

La transición de una viticultura tradicional, caracterizada por la aplicación profiláctica y continua de agroquímicos, hacia una viticultura de precisión es uno de los imperativos tecnológicos y ambientales más apremiantes de la agricultura moderna. En los sistemas de producción convencionales, la pulverización se realiza típicamente mediante pulverizadores hidroneumáticos de tasa constante que aplican productos químicos sobre toda la superficie del cultivo, independientemente de la presencia real de la enfermedad o de la biomasa foliar¹. Este enfoque genera que una proporción alarmante del volumen aplicado, a menudo inferior al 30% en términos de retención en el objetivo, se pierda en el medio ambiente a través de la deriva aérea y la escorrentía hacia el suelo². Estas ineficiencias no solo representan un costo económico superlativo para los productores vitivinícolas, sino que también exacerban la contaminación de los recursos hídricos, inducen el desarrollo de resistencias en los patógenos y amenazan la salud ocupacional de los trabajadores agrícolas³.

La pulverización de tasa variable (VRT) y los sistemas de aplicación selectiva basados en sensores ópticos ofrecen una solución transformadora, demostrando la capacidad de reducir el uso de pesticidas entre un 30% y un 85%, minimizando la escorrentía y la deriva sin comprometer en absoluto la eficacia biológica del control de enfermedades¹. En este contexto, el proyecto de final de estudios propuesto, que busca desarrollar un sistema de visión artificial y control co-simulado adaptativo para la pulverización selectiva de oídio (*Erysiphe necator*) en vid, se alinea perfectamente con la vanguardia de la robótica agrícola. La propuesta de integrar percepción visual mediante modelos de aprendizaje profundo con un control predictivo que modula una zona de amortiguamiento espacial basada en la dinámica epidemiológica y variables meteorológicas históricas, aborda una de las limitaciones más severas de los sistemas de pulverización óptica actuales: la incapacidad de tratar focos de infección microscópicos que ya han sido diseminados por la acción del viento⁶.

Este análisis exhaustivo evalúa la viabilidad del proyecto, confirmando la disponibilidad de conjuntos de datos y arquitecturas neuronales, analizando la dinámica del patógeno en la región de Mendoza, Argentina, y estructurando el marco teórico necesario para el desarrollo de la co-simulación mecatrónica.

Contexto Epidemiológico y Relevancia Geográfica en

Mendoza

Para diseñar un sistema de actuación autónoma, es fundamental comprender las variables biológicas que rigen el comportamiento del organismo objetivo. El oídio de la vid, causado por el hongo biótrofo obligado *Erysiphe necator* (sinónimo *Uncinula necator*), es la enfermedad fúngica más prevalente, persistente y destructiva en la viticultura de climas áridos y semiáridos⁹. Este perfil climático describe con precisión las condiciones de la provincia de Mendoza, Argentina, la principal región vitivinícola del país.

Dinámica Biológica del Oídio

A diferencia de otras enfermedades criptogámicas como la peronóspora (*Plasmopara viticola*), que requieren agua libre (lluvia) y alta humedad relativa para la germinación de sus esporangios, el oídio prospera en condiciones de sequedad ambiental, humedad moderada y temperaturas cálidas¹⁰. El patógeno infecta todos los tejidos verdes de la planta, incluyendo hojas, zarcillos, inflorescencias y bayas. Durante el invierno, el hongo sobrevive como micelio latente en las yemas infectadas durante la temporada anterior, o bien en forma de ascosporas contenidas dentro de estructuras de resistencia de paredes gruesas denominadas casmotecios (o cleistotecios) que se alojan en la corteza de las cepas¹⁴.

En la primavera, con el aumento de las temperaturas y las primeras precipitaciones o riegos que elevan la humedad localizada, los casmotecios liberan las ascosporas, iniciando la infección primaria¹³. Una vez que la infección primaria se establece, el hongo comienza a reproducirse asexualmente produciendo conidios. Estos conidios son estructuras ligeras y secas que son fácilmente transportadas por las corrientes de viento, dando lugar a múltiples ciclos de infección secundaria a lo largo de la temporada vegetativa⁷. La dependencia del viento para la dispersión de los conidios es el fundamento biológico que justifica la necesidad de un sistema de control predictivo que estime la distancia de deriva para aplicar un margen de seguridad en la pulverización⁶.

El Escenario Fitosanitario en la Región de Cuyo

En la provincia de Mendoza, el Instituto Nacional de Tecnología Agropecuaria (INTA) a través de su Estación Experimental Agropecuaria (EEA) Mendoza, realiza un seguimiento exhaustivo de la epidemiología del oídio, confirmando que la enfermedad requiere aplicaciones fungicidas rutinarias a lo largo de toda la campaña⁹. El impacto económico de estas aplicaciones preventivas es masivo. Además, el uso indiscriminado de fungicidas sistémicos, particularmente los inhibidores de la demetilación (DMI, FRAC 3) y los inhibidores externos de la quinona (QoI, FRAC 11) como las estrobilurinas, ha provocado la aparición de cepas de *Erysiphe necator* con resistencia genética a estos compuestos químicos en múltiples regiones vitivinícolas del mundo, lo que obliga a los productores a rotar ingredientes activos y optimizar las tasas de aplicación¹⁹. Un sistema de pulverización selectiva que reduzca el volumen de producto liberado al ambiente es la estrategia más eficaz para ralentizar la presión de selección que genera resistencia fúngica.

El análisis de la literatura confirma que, aunque el oídio es un objetivo primario ideal para el desarrollo del proyecto propuesto, existen otras plagas y enfermedades de extrema relevancia en Mendoza que podrían servir como objetivos alternativos o complementarios para un sistema

de visión artificial, cumpliendo con la premisa de evaluar alternativas locales.

La polilla de la vid (*Lobesia botrana*) representa una amenaza cuarentenaria de primer orden en la región cuyana²¹. El Instituto de Sanidad y Calidad Agropecuaria Mendoza (ISCAMEN) ejecuta enormes operativos anuales que abarcan más de 130.000 hectáreas, empleando tanto control químico directo como técnicas de confusión sexual mediante difusores de feromonas²¹. El daño inducido por las larvas de *Lobesia botrana* perfora las bayas, exponiendo los tejidos ricos en azúcares y creando la vía de entrada perfecta para patógenos fúngicos secundarios, particularmente *Botrytis cinerea* (podredumbre gris)²². Un sistema mecatrónico entrenado para detectar visualmente nidos de la polilla o los primeros signos de podredumbre en los racimos tendría un impacto agroindustrial inmediato.

Otra alternativa fitosanitaria es la peronóspora o mildiu de la vid (*Plasmopara viticola*). A diferencia del oídio, que se manifiesta como un polvo ceniciento en la superficie foliar, la peronóspora genera lesiones necróticas y manchas cloróticas translúcidas (conocidas como "manchas de aceite") en el haz de la hoja, acompañadas de una eflorescencia blanquecina en el envés²⁴. Estas lesiones presentan un contraste cromático mucho más marcado que el oídio, lo que estadísticamente facilita su detección por parte de redes neuronales convolucionales, haciendo de la peronóspora un excelente candidato alternativo si el entrenamiento del modelo para oídio presentara problemas de convergencia²⁶.

Modelado de Dinámica Epidemiológica: El Índice de Gubler-Thomas

El núcleo de la innovación propuesta radica en la capacidad del sistema de no solo observar el tejido visiblemente enfermo, sino de deducir el radio de diseminación invisible de las esporas. Esta deducción matemática requiere integrar el modelo de percepción visual con un modelo biológico predictivo. La literatura científica internacional en patología de la vid señala de forma unánime al Índice de Riesgo de Gubler-Thomas (GT) como el marco de referencia estándar para la modelización del oídio¹⁵.

Desarrollado en la Universidad de California, Davis, el modelo GT establece que el crecimiento de la colonia de *Erysiphe necator* y la duración de su ciclo reproductivo están regidos casi exclusivamente por las fluctuaciones de la temperatura ambiente¹⁴. Las temperaturas óptimas para el patógeno se encuentran en el rango de 21 °C a 30 °C. Las temperaturas inferiores ralentizan el metabolismo del hongo, mientras que las temperaturas superiores a 35 °C ejercen un efecto letal, destruyendo las colonias expuestas¹⁴.

Para que la co-simulación propuesta calcule con precisión la madurez de la infección, el algoritmo del subsistema de control debe procesar series temporales meteorológicas utilizando la siguiente lógica algorítmica iterativa:

1. **Condición de Iniciación:** Para que el ciclo epidémico secundario comience, el sistema debe registrar tres días consecutivos donde la temperatura se mantenga entre 21 °C y 30 °C por un mínimo de 6 horas continuas cada día¹⁴.
2. **Fase de Acumulación Diaria:** Una vez iniciado, el índice GT fluctúa entre un valor mínimo de 0 y un máximo de 100. Por cada día subsecuente que cumpla el requisito de 6

horas continuas entre 21 °C y 30 °C, el algoritmo suma 20 puntos al índice de riesgo¹⁴.

3. **Fase de Penalización Térmica:** Si en un período de 24 horas no se alcanzan las 6 horas en el rango óptimo, el algoritmo resta 10 puntos. Más críticamente, si la temperatura ambiental alcanza o supera los 35 °C durante al menos 15 minutos, se aplica una penalización directa restando 10 puntos adicionales, reflejando la mortalidad inducida térmicamente en la población de conidios¹⁴.

El valor numérico del índice de riesgo resultante se correlaciona directamente con la tasa de reproducción de la colonia fúngica, lo cual define el umbral temporal para la aplicación de agroquímicos.

Rango del Índice GT	Nivel de Riesgo Epidemiológico	Tasa de Reproducción del Patógeno	Intervalo de Pulverización Recomendado
0 - 30	Bajo	Inactivo o latente.	14 - 21 días (Intervalo máximo).
40 - 50	Moderado	Ciclo reproductivo cada 15 días.	10 - 17 días (Intervalo intermedio).
60 - 100	Alto / Crítico	Ciclo reproductivo explosivo cada 5 días.	7 - 14 días (Intervalo mínimo).
<i>Tabla 1: Relación entre el Índice de Riesgo de Gubler-Thomas, la biología del patógeno y los regímenes de actuación para agroquímicos sintéticos y azufre.¹⁴</i>			

En el entorno de co-simulación, el controlador utilizará el tamaño de la colonia detectada por la red neuronal (que actúa como un indicador de la biomasa fúngica actual) para estimar retrospectivamente cuántos días de crecimiento han transcurrido. Luego, aplicando el Índice GT sobre los datos meteorológicos de esos días previos, el algoritmo determinará la cantidad de conidios generados. Finalmente, integrando estos datos con un modelo de transporte de

dispersión euleriana o gaussiana impulsado por la velocidad y dirección histórica del viento, el controlador calculará el margen de seguridad asimétrico espacial ($L_{aplicacion}$). Esto instruirá a las válvulas de pulverización a activarse no solo sobre el tejido visiblemente detectado, sino también sobre el follaje adyacente donde las esporas han aterrizado de forma invisible⁶.

Revisión Crítica de Datasets Públicos para el Entrenamiento del Modelo

El mayor riesgo técnico en el desarrollo de sistemas de visión por computadora para aplicaciones agrícolas es la calidad y representatividad de los datos de entrenamiento. La capacidad del modelo para generalizar el aprendizaje depende directamente de la varianza ambiental contenida en el *dataset*.

El Riesgo del Aprendizaje por Atajos en PlantVillage

El documento inicial del proyecto sugiere el uso del conjunto de datos *PlantVillage*. Con más de 54,000 imágenes, es indiscutiblemente la colección de imágenes de enfermedades de plantas más accesible y citada en la literatura académica³⁷. Sin embargo, la adopción de este dataset para el entrenamiento de un modelo destinado a operar en un escenario agrícola real presenta un fallo metodológico crítico conocido como sesgo de fondo o aprendizaje por atajos (*shortcut learning*).

La totalidad de las imágenes contenidas en PlantVillage fueron capturadas en condiciones de laboratorio estériles. Las hojas enfermas fueron desprendidas de la planta y fotografiadas sobre fondos completamente homogéneos, generalmente papel gris o negro, bajo iluminación uniforme³⁷. Múltiples investigaciones empíricas han demostrado que las redes neuronales entrenadas con este dataset no aprenden a identificar la patología intrínseca de la hoja, sino que optimizan su función de pérdida mapeando los artefactos del fondo liso³⁷. De hecho, estudios como el de Noyan et al. (2022) demostraron que al entrenar un modelo proporcionando únicamente 8 píxeles del fondo de las imágenes de PlantVillage, sin incluir ninguna porción de la hoja, la red logró una precisión de clasificación del 49%, muy superior a la adivinanza aleatoria³⁷.

Cuando los modelos entrenados con PlantVillage se exponen a imágenes capturadas "en la naturaleza" (*in-the-wild*), donde el fondo incluye tierra, malezas, otras hojas superpuestas, variaciones de iluminación solar y sombras duras, la precisión de clasificación colapsa estrepitosamente desde un 99% en el entorno de validación del laboratorio a valores cercanos al 31% en el entorno operativo³⁷. Para un entorno de co-simulación que represente la dinámica visual de un espaldero real, depender de PlantVillage comprometería la solidez del sistema.

Datasets en Entornos Reales (*In-The-Wild*)

Para garantizar la robustez del modelo de percepción en entornos vitícolas complejos, el sistema debe ser entrenado con conjuntos de datos capturados directamente en el campo. Afortunadamente, la comunidad científica ha liberado recientemente repositorios excepcionales que documentan el oídio y otras enfermedades de la vid en condiciones reales, acompañados de anotaciones topológicas de alta fidelidad.

Nombre del Conjunto de Datos	Formato de Anotación	Volumen de Datos y Clases Vítícolas	Características y Aplicabilidad al Proyecto
PlantSeg	Máscaras de Segmentación a nivel de píxel.	11,400 imágenes. 115 enfermedades, incluyendo oídio en vid.	Capturado <i>in-the-wild</i> con fondos complejos. Permite a la red aislar topológicamente la lesión del fondo. Excelente para la estimación del área. ²⁸
LDD (Grape Diseases Dataset)	COCO (Máscaras y Bounding Boxes).	1,092 imágenes con 17,706 instancias anotadas.	Diseñado específicamente para enfermedades de la vid en su contexto natural. Incluye oídio, mildiu y podredumbre negra. ⁴⁴
PlantDoc	PASCAL VOC / YOLO (Bounding Boxes).	2,598 imágenes de campo abierto. 29 clases de enfermedades.	Ideal para tareas rápidas de detección de objetos, aunque los cuadros delimitadores incluyen píxeles de fondo. ⁴⁶
NGLD (Niphad Grape Leaf Disease)	Clasificación de imágenes (256x256 píxeles).	2,726 imágenes de campo. Clases: Sano, Oídio, Mildiu, Bacteriosis.	Colección muy reciente (2025) de hojas de vid en campo. Útil para clasificación binaria o multiclase. ⁴⁹
Embrapa WGISD	Máscaras y	300 imágenes, 4,432 racimos	Exclusivo para la segmentación de

	Bounding Boxes.	anotados de 5 variedades.	racimos de uva en sistemas de espaldera, capturando oclusión foliar. ⁵²
<i>Tabla 2: Análisis comparativo de conjuntos de datos públicos aplicables al entrenamiento de modelos de detección de enfermedades en viticultura de precisión.</i>			

Desde una perspectiva arquitectónica, el anteproyecto propone inferir la severidad biológica a partir del "área del cuadro delimitador" (*bounding box*). Esta aproximación geométrica induce un sesgo de cuantificación importante, ya que las colonias de oídio tienen contornos amorfos y difusos; un rectángulo que encierre la lesión inevitablemente incluirá un alto porcentaje de tejido sano o espacio vacío del fondo⁵⁵.

Para lograr el acoplamiento perfecto entre la percepción visual y la ecuación epidemiológica de dispersión, se recomienda encarecidamente utilizar la tarea de **Segmentación de Instancias** apoyada por los datasets *LDD* o *PlantSeg*. Al generar una máscara binaria exacta a nivel de píxel sobre el micelio fúngico, el modelo de visión proporcionará al controlador mecatrónico un

valor de área de lesión (A_{lesion}) biológicamente preciso, lo que resulta en una inferencia mucho más fidedigna de la madurez de la colonia fúngica⁴⁴.

Arquitecturas de Visión Artificial: YOLOv8 vs YOLOv11

El subsistema de visión de la arquitectura co-simulada debe procesar flujos de video secuenciales de los espalderos, identificar las colonias patógenas, extraer sus coordenadas cartesianas relativas respecto a la cámara y cuantificar su área, todo ello sujeto a las severas restricciones de latencia inherentes al control en tiempo real⁶. La detección de objetos en un solo paso (*one-stage object detection*) dictada por la familia de algoritmos YOLO ha demostrado superioridad técnica en el dominio agrícola al ofrecer el mejor equilibrio entre la precisión media promedio (mAP) y los fotogramas por segundo (FPS) procesados⁵⁸.

Las manchas tempranas de oídio presentan un contraste visual ínfimo respecto a la cutícula verde de la hoja, manifestándose como finas tramas aracnoideas o un polvo ceniciento que a menudo se confunde con reflejos especulares de luz solar o polvo inorgánico en suspensión³⁰.

Esto ubica el problema dentro de la disciplina de "detección de pequeños objetivos" (*small target detection*), la cual se ve dificultada por el desenfoque de movimiento (*motion blur*) causado por la cinemática del tractor y las oclusiones parciales de las hojas en movimiento⁶³. Ambas versiones evaluadas, YOLOv8 y YOLOv11, son herramientas de vanguardia, pero la iteración más reciente incorpora topologías optimizadas para este escenario específico.

Evolución Estructural y Retención de Gradientes

La arquitectura YOLOv8 basó su éxito en el módulo de extracción de características C2f y en una cabeza de detección sin anclas (*anchor-free*), logrando segmentar estructuras biológicas con notable fluidez y una baja huella computacional en dispositivos de borde (*edge devices*)⁶⁰. No obstante, ante lesiones difusas como las del oídio, YOLOv8 frecuentemente experimenta degradación de las características espaciales de grano fino en las capas más profundas de la red neuronal⁶².

YOLOv11, lanzado como un rediseño holístico de la arquitectura base, soluciona estas deficiencias estructurales a través de tres innovaciones fundamentales aplicables a la detección fitosanitaria:

1. **Sustitución del módulo C2f por C3k2:** En la red troncal (*backbone*), el bloque C3k2 implementa conexiones residuales de doble rama que estabilizan la propagación del gradiente hacia adelante y hacia atrás. Esto permite a la red retener y fusionar características semánticas de muy baja escala (inferiores a 2 milímetros en la imagen), cruciales para identificar los primeros síntomas microscópicos del ataque fúngico⁵⁵.
2. **Mecanismos de Atención Espacial (C2PSA):** La introducción de bloques de atención espacial en la arquitectura base permite al algoritmo ponderar dinámicamente qué regiones de los mapas de características contienen información relevante, forzando a la red a enfocarse en los patrones patológicos sutiles y a suprimir la interferencia de los fondos complejos, ramas cruzadas y reflejos lumínicos del viñedo⁶².
3. **Funciones de Pérdida Optimizadas:** La integración de métricas de pérdida de regresión de cajas más sofisticadas, como la distancia de Wasserstein normalizada (NWD), mitiga severamente los errores de penalización que ocurren cuando se detectan objetivos diminutos y superpuestos, lo cual es el estándar en la morfología del oídio y la peronospora⁵⁵.

Rendimiento Computacional y Despliegue en el Borde

Para la co-simulación propuesta, donde el código Python debe compartir recursos de la CPU/GPU con los motores físicos de Simulink, la eficiencia paramétrica es tan crítica como la precisión. Pruebas comparativas en laboratorios agronómicos demuestran que YOLOv11 mejora el mAP en un rango del 2% al 5.5% frente a YOLOv8 en conjuntos de datos de hojas de cultivos, al tiempo que reduce el conteo total de parámetros hasta en un 22%⁵⁵.

Arquitectura de Red Neuronal	Complejidad Estructural	Precisión en Detección de Hojas/Lesiones	Ventajas para la Co-Simulación y Despliegue
------------------------------	-------------------------	--	---

YOLOv8-seg (Nano/Small)	Módulo C2f en el Backbone.	Alta precisión general, pero sufre decaimiento con manchas foliares minúsculas.	Estabilidad comprobada, compatibilidad absoluta con librerías clásicas. Excelente velocidad de inferencia. ⁶⁰
YOLOv11-seg (Nano/Small)	Módulo C3k2, Atención Espacial C2PSA.	mAP superior en un 2-5% para objetivos densos, ocluidos y sutiles.	Reducción del 22% en parámetros. Menor demanda de VRAM, ideal para hardware embebido y co-simulación pesada. ⁵⁵
<i>Tabla 3: Comparativa arquitectónica entre modelos de la familia YOLO para aplicaciones de segmentación en tiempo real en viticultura.</i>			

De cara al futuro despliegue del sistema en un prototipo físico de tractor, la viabilidad de estos modelos en computadoras de a bordo ha sido validada exhaustivamente. El despliegue de las versiones ligeras de YOLOv11 (Nano o Small) optimizadas con TensorRT en plataformas de aceleración embebida como la **NVIDIA Jetson Orin NX** o **Jetson Xavier** permite procesar la segmentación de instancias agrícolas a velocidades de 30 a 50 FPS con latencias de inferencia de 20 a 38 milisegundos, operando con un consumo energético minúsculo (inferior a 15 vatios) que es fácilmente alimentable por el sistema eléctrico del vehículo agrícola⁵⁶. Por lo tanto, la elección de YOLOv11-seg como el núcleo del modelo de percepción en el anteproyecto garantizará una resolución geométrica excepcional y una integración computacional fluida.

Arquitectura de Co-Simulación y Control Mecatrónico

La etapa que confiere al proyecto de estudios su verdadero carácter multidisciplinario es la integración del modelo de visión artificial (desarrollado en un entorno de Python) con la dinámica física del sistema de actuación de fluidos (desarrollado en MATLAB/Simulink). Esta arquitectura de co-simulación ciberfísica exige un diseño algorítmico riguroso para replicar las condiciones operativas de campo.

Protocolos de Comunicación Inter-Procesos (IPC)

La propuesta de simplificar la comunicación mediante *sockets* es técnicamente correcta y fundamental para evitar cuellos de botella por latencia⁶. El script de Python, alojando la inferencia de YOLOv11, operará como un servidor asíncrono. Por cada *frame* analizado, Python serializará los datos de detección en un vector estructurado que contenga: la clase del patógeno detectado, las coordenadas cartesianas del centroide de la lesión relativas al encuadre espacial de la cámara (X, Y) y el área topológica calculada por la máscara de segmentación (A_{lesion}).

Este vector de datos será transmitido mediante un protocolo de datagramas de usuario (UDP) o un protocolo de control de transmisión (TCP) hacia el entorno Simulink⁷³. MATLAB operará como el cliente, recibiendo la telemetría visual a la tasa de muestreo dictada por la inferencia

neuronal (por ejemplo, a intervalos discretos $T_s \approx 0.033$ segundos para un flujo de 30 FPS). Este flujo ininterrumpido de variables de estado alimentará el módulo central del sistema: el algoritmo de Planificación y Control Adaptativo.

Dinámica Fluidodinámica y Compensación de Tiempos Muertos

El desafío supremo en la robótica de pulverización agrícola no es únicamente detectar la maleza o la enfermedad, sino actuar la válvula electromagnética en el instante exacto en que la boquilla aspersora se encuentra físicamente alineada sobre el objetivo biológico¹. En un sistema en movimiento continuo, cualquier retardo no compensado resultará en que el agroquímico sea depositado erróneamente sobre follaje sano o en el suelo vacío, anulando las premisas de la viticultura de precisión.

Para que la co-simulación en Simulink sea válida y publicable, el modelo matemático debe incorporar todas las fuentes de latencia del dominio del tiempo:

1. **Retardo Computacional (*Transport Delay*):** El tiempo discreto que transcurre desde la adquisición del fotograma hasta que YOLO exporta los tensores resultantes a Simulink. En plataformas físicas modernas, este retardo oscila entre los 20 y 40 milisegundos y puede ser modelado linealmente en Simulink⁶⁷.
2. **Cinemática de Translación:** Un bloque integrador computará la velocidad instantánea

de avance del tractor virtual ($v_{tractor}$). Conociendo la separación física longitudinal entre el plano de la cámara y la ubicación de la barra de pulverización ($d_{camara-boquilla}$), el sistema determina el tiempo de vuelo físico:

$d_{camara-boquilla}$), el sistema determina el tiempo de vuelo físico:

$$T_{viaje} = d_{camara-boquilla} / v_{tractor} \quad 1.$$

3. **Inercia Electromecánica de las Válvulas PWM:** Las boquillas controladas por modulación de ancho de pulso (PWM) gobiernan el flujo abriendo y cerrando solenoides a altas frecuencias. Estas válvulas poseen una respuesta transitoria no lineal dominada por la inductancia electromagnética de la bobina y la fricción fluida⁷⁴. En la co-simulación, esto no debe representarse como un bloque de paso ideal (función escalón), sino

mediante funciones de transferencia de primer o segundo orden con tiempos muertos, modelando el retardo inherente a la apertura de la aguja inyectora.

La lógica de control computará entonces un temporizador estocástico que dispare el pulso de actuación PWM exactamente cuando

$$T_{viaje} - (T_{retardo_computacional} + T_{respuesta_valvula}) = 0 \quad ^1.$$

Esta integración matemática entre el dominio discreto de la inteligencia artificial y el dominio continuo de la física de fluidos asegurará que las gotas del fungicida atomizado impacten con precisión nanométrica sobre el tejido vegetal designado.

Integración de la Dinámica Epidemiológica

A diferencia de los sistemas ópticos binarios tradicionales (que actúan abriendo la válvula solo cuando el sensor "ve" una hoja), el proyecto introduce la variable epidemiológica⁴. El

subsistema de control tomará el área de la lesión detectada (A_{lesion}) y la utilizará en una

función de regresión logística para deducir el tiempo t (en días) transcurrido desde el inicio de la infección¹⁹.

Simultáneamente, consultará una serie de tiempo meteorológica virtual para computar el Índice

de Gubler-Thomas durante esos t días históricos, estimando la densidad de esporulación.

Multiplicando la intensidad de esporulación por los vectores de la velocidad del viento dominante en la simulación, el sistema calculará un umbral de dispersión o zona de

amortiguamiento dinámico ($L_{aplicacion}$)⁷. El comando temporal enviado a la válvula PWM ya no será un pulso discreto equivalente al tamaño del cuadro delimitador, sino un pulso de mayor longitud de onda que esparcirá fungicida espacialmente cubriendo tanto el foco madre visible como el radio periférico donde la física de dispersión indica que han aterrizado las esporas latentes.

Análisis de Riesgos Estructurales y

Recomendaciones Finales

El PFE propuesto por Sorrentino constituye una tesis de integración mecatrónica excepcionalmente creativa, fundamentada en sólidos principios físicos y biológicos, que ofrece una solución plausible a una grave deficiencia en la tecnología actual de pulverización autónoma¹. Las tecnologías subyacentes son maduras y la literatura confirma ampliamente su pertinencia empírica.

No obstante, un análisis pragmático del cronograma operativo propuesto revela un riesgo de viabilidad severo que el estudiante debe recalibrar para asegurar la consecución de los objetivos.

El diagrama de Gantt estipula la completitud del desarrollo e integración en un plazo sumamente agresivo de 2 meses (8 semanas)⁶. En el ecosistema del aprendizaje profundo, el proceso aislado de recolección de un dataset, depuración, particionado de datos, configuración de la topología neuronal y entrenamiento a través de docenas de épocas hasta lograr la

convergencia puede consumir holgadamente de 3 a 5 semanas. Si el estudiante pretendiera además capturar y etiquetar polígonos de oídio manualmente en un software de anotación, el cronograma colapsaría irreversiblemente en la fase inicial. La subsiguiente creación del entorno de simulación fluida en MATLAB y el *debugging* de la arquitectura de comunicación por *sockets* en tiempo real presenta un alto grado de complejidad sistémica que absorberá las semanas restantes⁷³.

Para mitigar proactivamente este riesgo de alcance y asegurar una defensa académica exitosa, se emiten las siguientes directrices estratégicas de ingeniería:

- **Abandono de PlantVillage y Adopción Inmediata de LDD o PlantSeg:** Se desaconseja categóricamente la recolección de datos propios o el uso de PlantVillage debido a la alta incidencia de sesgo de fondo (*shortcut learning*)³⁷. El alumno debe descargar el conjunto de datos de dominio público **LDD (Leaf Diseases Dataset)** u **PlantSeg**, los cuales ya cuentan con miles de imágenes capturadas en campo y con sus respectivas máscaras de segmentación generadas en formato COCO⁴². Esto reducirá el tiempo de la etapa 1 del cronograma a escasos días.
- **Aprendizaje por Transferencia sobre YOLOv11:** En lugar de construir una red convolucional desde cero, se debe emplear un script de entrenamiento basado en la API de Ultralytics utilizando los pesos preentrenados del modelo **YOLOv11n-seg** o **YOLOv11s-seg**⁵⁵. El *transfer learning* permitirá al modelo aprender los patrones texturales del oídio en unas pocas horas de entrenamiento en GPU, garantizando la extracción de áreas precisas con una latencia mínima.
- **Modularidad de la Simulación Física:** Al construir el entorno de Simulink, es imperativo priorizar un enfoque modular escalonado. Se recomienda implementar primero un controlador puramente cinemático (ignorando inicialmente las no-linealidades hidrodinámicas de las boquillas) para establecer la fiabilidad del lazo de comunicación Python-MATLAB y demostrar la lógica de extensión de la zona de amortiguamiento (*L_{aplicacion}*) basada en datos de viento. Una vez que este circuito de control básico opere sin errores de sincronización de tiempo, el estudiante podrá incrementar la fidelidad del sistema acoplando modelos físicos de válvulas de retardo.

Con la aplicación rigurosa de estas estrategias de mitigación, la incorporación metodológica de los modelos meteorológicos de Gubler-Thomas y la sustitución arquitectónica hacia técnicas de segmentación de instancias verdaderas para evadir las limitaciones biológicas de las cajas delimitadoras, el proyecto de final de estudios posee todos los elementos estructurales para consolidarse como un avance significativo en el estado del arte de la ingeniería de maquinaria agrícola autónoma. La convergencia sinérgica entre el procesamiento de imágenes, la aerodinámica teórica y la teoría de control robusto posibilitará que las futuras arquitecturas robóticas no solo ataquen las plagas de manera reactiva, sino que modulen sus defensas anticipándose a la propagación latente dictada por el entorno climatológico.

Fuentes citadas

1. Development and Laboratory Evaluation of a Plant Detection-Based,

- <https://www.mdpi.com/2624-7402/8/8/304>
2. Opportunities and Possibilities of Developing an Advanced ... - MDPI, <https://www.mdpi.com/1424-8220/21/9/3262>
 3. (PDF) Advanced spraying systems to improve pesticide saving and, https://www.researchgate.net/publication/370899684_Advanced_spraying_systems_to_improve_pesticide_saving_and_reduce_spray_drift_for_apple_orchards
 4. Selective spraying of grapevines for disease control using a modular, https://www.researchgate.net/publication/290480249_Selective_spraying_of_grapevines_for_disease_control_using_a_modular_agricultural_robot
 5. Grape clusters and foliage detection algorithms for autonomous, https://www.researchgate.net/publication/225463928_Grape_clusters_and_foliage_detection_algorithms_for_autonomous_selective_vineyard_sprayer
 6. Anteproyecto PFE - Sistema de Visión Artificial y Control Co-simulado Adaptativo.pdf
 7. Dispersal of foliar plant pathogens: mechanisms, gradients and, https://www.researchgate.net/publication/226981555_Dispersal_of_foliar_plant_pathogens_mechanisms_gradients_and_spatial_patterns
 8. The Ebb and Flow of Airborne Pathogens: Monitoring and Use in, https://www.researchgate.net/publication/299375464_The_Ebb_and_Flow_of_Airborne_Pathogens_Monitoring_and_Use_in_Disease_Management_Decisions
 9. Manual Carozo | PDF | Plaga (organismo) | Pesticida - Scribd, <https://es.scribd.com/document/568510364/Manual-Carozo>
 10. Common Diseases of Vitis Vinifera: Identification and Management, <https://vitisviniferaauthority.com/vitis-vinifera-diseases/>
 11. Historia de la ALF (1964 – 2009 - Biblioteca Digital INIA, <https://biblioteca.inia.cl/bitstreams/771c99f8-49e0-4ff7-88d4-141fe4148b69/download>
 12. CP-1 MANEJO INTEGRADO DE ENFERMEDADES EN, <https://sef.es/sites/default/files/LloretdeMar2004.pdf>
 13. Application to Grape Powdery Mildew (Erysiphe necator) in Vineyards, <https://www.mdpi.com/2073-4395/10/5/622>
 14. Use of the UC Davis Powdery Mildew Risk Index, <https://ucanr.edu/media/306465>
 15. Effect of environmental conditions and phenology in the dispersal of, <https://ojs.openagrar.de/index.php/VITIS/article/view/14823/14620>
 16. Untitled - Oregon State University, <https://ir.library.oregonstate.edu/downloads/ff365799f>
 17. Agricultural Systems - Semantic Scholar, <https://pdfs.semanticscholar.org/ebf1/ed88f1557e948a488e0f712a38bcd0cf9acf.pdf>
 18. (PDF) Un ejemplo de agroforestería vitícola: los sistemas de uvas, https://www.researchgate.net/publication/354521467_Un_ejemplo_de_agroforesteria_viticola_los_sistemas_de_uvas_tradicionales_del_Valle_de_los_Cintis_Bolivia?_tp=eyJjb250ZXh0Ijp7InBhZ2UiOiJzY2llbnRpZmliQ29udHJpYnV0aW9ucyIsInByZXZpb3VzUGFnZSI6bnVsbCwic3ViUGFnZSI6bnVsbH19
 19. (PDF) Revising the high temperature threshold for the Gubler,

- https://www.researchgate.net/publication/294394144_Revising_the_high_temperature_threshold_for_the_Gubler-Thomas_grape_powdery_mildew_risk_index
20. Plant Health 2021 Abstracts of Presentations - APS Journals,
<https://apsjournals.apsnet.org/doi/pdf/10.1094/PHTO-111-10-S2.1>
 21. ISCAMEN: Con una importante concurrencia se desarrolló la jornada,
<https://radioregional.com.ar/iscamen-con-una-importante-concurrencia-se-desarrollo-la-jornada-prevencion-clima-y-produccion/>
 22. Control de plagas y enfermedades emergentes: tecnología y ... - Fruto,
<https://benditofruto.ar/control-de-plagas-y-enfermedades-emergentes-tecnologia-y-manejo-inteligente-en-el-vinedo-del-futuro/>
 23. Plagas: Mendoza propone que se declare libre de Mosca del,
<https://www.losandes.com.ar/fincas/plagas-mendoza-propone-que-se-declare-libre-de-mosca-del-mediterraneo-a-ugarteche-y-a-la-paz>
 24. A comparative study of plant-pathogen interaction in,
https://openpub.fmach.it/retrieve/e1dbfeab-064d-4ac9-e053-1705fe0a1c61/Thesis_PhD_Buonassisi_Daniele.pdf
 25. Deep semantic segmentation for the quantification of grape foliar,
<https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2022.978761/full>
 26. [PDF] Towards Automatic Detection and Quantification of Mildew on,
<https://www.semanticscholar.org/paper/Towards-Automatic-Detection-and-Quantification-of-Iqbal-Sargent/e85a72339f5dd68c8976354d60f9187bfe270888>
 27. Grape Leaf Disease Images Collection - Kaggle,
<https://www.kaggle.com/datasets/freshersstaff/grape-leaf-disease-images-collection>
 28. Gradient-guided boundary-aware selective scanning with multi,
<https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2025.1727075/full>
 29. Modeling Uncertainty in Grapevine Powdery Mildew Epidemiology,
https://www.researchgate.net/publication/345657353_Modeling_Uncertainty_in_Grapevine_Powdery_Mildew_Epidemiology_Using_Fuzzy_Logic
 30. Disease models - strawberry - METOS by Pessl Instruments,
<https://metos.global/en/disease-models-strawberry/>
 31. Fighting Disease Organically - Wines & Vines,
https://winebusinessanalytics.com/sections/printout_article.cfm?content=58955&article=feature
 32. Effect of High Temperature and Exposure Time on Erysiphe necator,
https://www.researchgate.net/publication/239939354_Effect_of_High_Temperature_and_Exposure_Time_on_Erysiphe_necator_Growth_and_Reproduction_Revisions_to_the_UC_Davis_Powdery_Mildew_Risk_Index
 33. Mildew Risk Models - Wildeye Support,
<https://info.mywildeye.com/info/mildew-risk-models>
 34. Comparative efficiency and residue levels of spraying programs,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12326300/>
 35. 6 "Pollen Resilience Index": Combined Impact of Air Pollution,

- https://www.bioairmet.ptb.de/fileadmin/epm2023/bioairmet/Abstract-book_WAB_July_2024.pdf
36. Spatial interpolation methods to predict airborne pesticide drift,
https://www.researchgate.net/publication/341806581_Spatial_interpolation_methods_to_predict_airborne_pesticide_drift_deposits_on_soils_using_knapsack_sprayers
 37. (PDF) Uncovering bias in the PlantVillage dataset - ResearchGate,
https://www.researchgate.net/publication/361206326_Uncovering_bias_in_the_PlantVillage_dataset
 38. A Light Weight Multi-Features-View Convolution Neural Network For,
<https://arxiv.org/html/2605.00903v1>
 39. An Interpretable Framework for Uncovering Shortcut Learning in,
https://jscit.nit.ac.ir/article_242549_40ad8364ee9a2546a09cea8dbd2f1389.pdf
 40. Augmented Grape Leaf Disease Dataset for Realistic Vineyard,
https://www.researchgate.net/publication/396522974_Augmented_Grape_Leaf_Disease_Dataset_for_Realistic_Vineyard_Environment_using_Background_Blending
 41. AgriPath: A Systematic Exploration of Architectural Trade-offs ... - arXiv,
<https://arxiv.org/html/2603.13354v1>
 42. PlantSeg-segmentation-dataset Semantic ... - Roboflow Universe,
<https://universe.roboflow.com/uqtwei-6gmpn/plantseg-segmentation-dataset>
 43. A Large-Scale In-the-wild Dataset for Plant Disease Segmentation,
https://www.researchgate.net/publication/400601599_A_Large-Scale_In-the-wild_Dataset_for_Plant_Disease_Segmentation
 44. Idd-a-grape-diseases-dataset-detection-and-instance ... - SciSpace,
<https://scispace.com/pdf/idd-a-grape-diseases-dataset-detection-and-instance-y1b9loun.pdf>
 45. LDD: A Dataset for Grape Diseases Object Detection and Instance,
https://www.researchgate.net/publication/361457929_LDD_A_Dataset_for_Grape_Diseases_Object_Detection_and_Instance_Segmentation
 46. GRAPE Leaf Diseases - Kaggle,
<https://www.kaggle.com/datasets/yusufmurtaza01/grape-leaf-diseases>
 47. Plant Disease Detection using PlantDoc and YOLOv5 · GitHub,
https://github.com/kruthi-sb/leaf_disease_detection
 48. A Unified Self-Supervised Framework for Plant Disease Detection,
<https://www.mdpi.com/2079-9292/14/17/3410>
 49. Niphad_Grapeleaf_Disease_Dat,
<https://www.kaggle.com/datasets/adibamuttaqin/niphad-grapeleaf-disease-dataset>
 50. Grapes leaf disease dataset for precision agriculture - PMC - NIH,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12210286/>
 51. Niphad Grape Leaf Disease Dataset (NGLD) - Mendeley Data,
<https://data.mendeley.com/datasets/8nnd2ypcv3/4>
 52. WGISD - Dataset Ninja, <https://datasetninja.com/wgisd>
 53. thsant/wgisd: Embrapa Wine Grape Instance Segmentation Dataset,
<https://github.com/thsant/wgisd>

54. Grape detection, segmentation, and tracking using deep neural, <https://ar5iv.labs.arxiv.org/html/1907.11819>
55. DMN-YOLO: A Robust YOLOv11 Model for Detecting Apple Leaf, <https://www.mdpi.com/2077-0472/15/11/1138>
56. Grapevine Winter Pruning Point Localization Using YOLO-Based, <https://www.mdpi.com/2077-0472/16/9/943>
57. A Large-Scale In-the-wild Dataset for Plant Disease Segmentation, https://www.researchgate.net/publication/383863700_PlantSeg_A_Large-Scale_In-the-wild_Dataset_for_Plant_Disease_Segmentation
58. YOLOv9-SEDA: A Lightweight Object Detection Framework for, <https://www.preprints.org/manuscript/202505.1510>
59. LeafDet: A lightweight and interpretable deep learning framework for, <https://journals.plos.org/plosone/article/file?type=printable&id=10.1371/journal.pone.0349501>
60. EdgeLane-SEG: an energy-efficient embedded edge AI framework, <https://www.frontiersin.org/journals/artificial-intelligence/articles/10.3389/frai.2026.1872217/full>
61. Code-Institute-Submissions/mildew-detector-21 - GitHub, <https://github.com/Code-Institute-Submissions/mildew-detector-21>
62. Apple Leaf Disease Detection Based on Improved YOLOv11 ... - PMC, <https://pmc.ncbi.nlm.nih.gov/articles/PMC13306718/>
63. Research on Apple Surface Disease Detection Method Based on, <https://pmc.ncbi.nlm.nih.gov/articles/PMC13164482/>
64. A Tomato Maturity Detection Algorithm Based on Improved YOLOv11, <https://www.mdpi.com/2076-3417/15/9/5000>
65. Learning from Motion. A Dynamic Feature Fusion Framework for, https://www.researchgate.net/publication/400403281_Learning_from_Motion_A_Dynamic_Feature_Fusion_Framework_for_Robust_Agricultural_Vision_in_Blurred_Environments
66. YOLOv8n-Seg-Based Grape Berry Instance Segmentation and, <https://www.mdpi.com/2311-7524/12/6/697>
67. GarbageIQ: A Real-Time AI-Powered Waste Classification ... - ijsrem, https://ijsrem.com/uploads/articles/1779788280152-5d0b68966093-GarbageIQ_IEEE_Paper.pdf
68. (PDF) Embedded Vision System Using YOLOv8 on Jetson Orin NX, https://www.researchgate.net/publication/403105341_Embedded_Vision_System_Using_YOLOv8_on_Jetson_Orin_NX
69. YOLO-lychee-advanced: an optimized detection model for ... - Frontiers, <https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2025.1643700/full>
70. Frequency-domain attention enhanced YOLOv11-EfficientFormerV2, <https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2026.1876223/full>
71. RESEARCH ON GRAPE DISEASE DETECTION METHOD BASED, https://www.researchgate.net/publication/413753027_RESEARCH_ON_GRAPE

[DISEASE_DETECTION_METHOD_BASED_ON_PWE-YOLO](#)

72. FEGW-YOLO: A Feature-Complexity-Guided Lightweight Framework,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12944136/>
73. Teaching the Implementation of Digital Control using Proteus VSM,
https://www.researchgate.net/publication/338632159_Teaching_the_Implementation_of_Digital_Control_using_Proteus_VSM_Software
74. Contents | IET Conference Proceedings 2024, 13,
<https://digital-library.theiet.org/toc/icp/2024/13>
75. Electronics, Volume 15, Issue 15 (August-1 2026) – 252 articles,
<https://www.mdpi.com/2079-9292/15/15>
76. Tagungsband ASIM Workshop GMMS/STS 2025 - electronic library -,
https://elib.dlr.de/219456/1/arep.48_OA.pdf